Задание

Выбор варианта задания

Исходные данные:

- Факультет **ИУ**, кафедра **ИУ5**
- Учебная группа: **ИУ5-22М**
- Порядковый номер в группе на 23.03.2024: **15**

На основании этих данных были получены следующие задания:

Задача 1	Задача 2
15	35

Также имеется дополнительное требование для группы:

- Для студентов групп ИУ5-22М, ИУ5И-22М - для произвольной колонки данных построить гистограмму.

Условия задач

Ниже представлены условия выданных задач

Задача №15

Для набора данных проведите нормализацию для одного (произвольного) числового признака с использованием функции "возведение в степень".

Задача №35

Для набора данных проведите процедуру отбора признаков (feature selection). Используйте метод вложений (embedded method). Используйте подход на основе дерева решений.

Ход выполнения работы

Текстовое описание набора данных

В качестве набора данных используется dataset рейтингов университетов мира на основании трёх рейтингов. Датасет доступен по адресу: https://www.kaggle.com/mylesoneill/world-university-rankings

Из набора данных будет рассматриваться только файл `cwurData.csv` .

Описание столбцов:

- `world_rank` - мировой рейтинг университета
- `institution` - название университета
- `country` - страна, в которой расположен университет
- `national_rank` - рейтинг университета в стране его нахождения
- `quality_of_education` - рейтинг качества образования
- `quality_of_faculty` - рейтинг качества профессорско-преподавательского состава
- `publications` - рейтинг публикаций
- `infuence` - рейтинг влияния
- `citations` - количество студентов в университете
- `broad_impact` - рейтинг за широкое влияние (предоставлен только за 2014 и 2015 гг. Остальное - пропуски)
- `patents` - рейтинг за патенты
- `score` - общий балл, используемый для определения мирового рейтинга
- `year` - год рейтинга (с 2012 по 2015 год)

Основные характеристики набора данных

Подключаем все необходимые библиотеки

In [25]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib
import matplotlib_inline
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
import scipy.stats as stats
from sklearn.tree import DecisionTreeRegressor
```
Подключаем Dataset

In [26]:
```
data = pd.read_csv('cwurData.csv', sep=",")
```
Размер набора данных

In [27]:
```
data.shape
```
Out[27]:
```
(2200, 14)
```
Типы колонок

In [28]:
```
data.dtypes
```
Out[28]:
```
world_rank              int64
institution            object
country                object
national_rank           int64
quality_of_education    int64
alumni_employment       int64
quality_of_faculty      int64
publications            int64
influence               int64
citations               int64
broad_impact          float64
patents                 int64
score                 float64
year                    int64
dtype: object
```
Проверяем, есть ли пропущенные значения

In [29]:
```
data.isnull().sum()
```
Out[29]:
```
world_rank              0
institution             0
country                 0
national_rank           0
quality_of_education    0
alumni_employment       0
quality_of_faculty      0
publications            0
influence               0
citations               0
broad_impact          200
patents                 0
score                   0
year                    0
dtype: int64
```
Первые 5 строк датасета

In [30]:
```
data.head()
```

Out[30]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	publi
0	1	Harvard University	USA	1	7	9	1	
1	2	Massachusetts Institute of Technology	USA	2	9	17	3	
2	3	Stanford University	USA	3	17	11	5	
3	4	University of Cambridge	United Kingdom	1	10	24	4	
4	5	California Institute of Technology	USA	4	2	29	7	

In [31]:
```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```
Всего строк: 2200

Процент пропусков в `broad_impact`

In [32]:
```
(200 / 2200) * 100
```
Out[32]:
9.090909090909092

Настройка отображения графиков

In [33]:
```
# Задание формата графиков для сохранения высокого качества PNG
from IPython.display import set_matplotlib_formats
matplotlib_inline.backend_inline.set_matplotlib_formats("retina")
# Задание ширины графиков, чтобы они помещались на A4
```

Обработка пропусков данных

Очистка строк

Можно очистить строки, содержащие пропуски. При этом останутся данные только за 2014 и 2015 гг (см. описание датасета)

In [34]:
```
# Удаление строк, содержащих пустые значения
data_no_null = data.dropna(axis=0, how='any')
(data.shape, data_no_null.shape)
```
Out[34]:
((2200, 14), (2000, 14))

Выведем первые 11 строк, чтобы убедиться, что данные в `national_rank` числовые (Jupyter Lab в предпросмотре CSV показывает не совсем верно)

In [35]:
```
data_no_null.head(11)
```

Out[35]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	pul
200	1	Harvard University	USA	1	1	1	1	
201	2	Stanford University	USA	2	11	2	4	
202	3	Massachusetts Institute of Technology	USA	3	3	11	2	
203	4	University of Cambridge	United Kingdom	1	2	10	5	
204	5	University of Oxford	United Kingdom	2	7	12	10	
205	6	Columbia University	USA	4	13	8	9	
206	7	University of California, Berkeley	USA	5	4	22	6	
207	8	University of Chicago	USA	6	10	14	8	
208	9	Princeton University	USA	7	5	16	3	
209	10	Yale University	USA	8	9	25	11	
210	11	Cornell University	USA	9	12	18	19	

In [36]:
```
total_count = data_no_null.shape[0]
print('Всего строк: {}'.format(total_count))
```
Всего строк: 2000

Кодирование категориальных признаков

Преобразуем названия стран, городов, ... в числовые зеачения (label encoding). Это необходимо для задания №35

In [37]:
```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```
<=========> institution <==========

In [38]:
```
le = LabelEncoder()
institution_le = le.fit_transform(data_no_null['institution'])
```
In [39]:
```
data_no_null['institution'].unique()
```
Out[39]:
```
array(['Harvard University', 'Stanford University',
       'Massachusetts Institute of Technology', ...,
       'Babeș-Bolyai University', 'Henan Normal University',
       'Southwest Jiaotong University'], dtype=object)
```
In [40]:
```
arr_institution_encoded = np.unique(institution_le)
arr_institution_encoded
```
Out[40]:
```
array([   0,    1,    2, ..., 1020, 1021, 1022])
```
In [41]:
```
le.inverse_transform([n for n in range(1023)])
```

Out[41]:
```
array(['AGH University of Science and Technology', 'Aalborg University',
       'Aalto University', ..., 'École normale supérieure de Cachan',
       'École normale supérieure de Lyon', 'Örebro University'],
      dtype=object)
```
```
=========> country <==========
```
In [42]:
```
le_country = LabelEncoder()
country_le = le_country.fit_transform(data_no_null['country'])
```
In [43]:
```
data_no_null['country'].unique()
```
Out[43]:
```
array(['USA', 'United Kingdom', 'Japan', 'Switzerland', 'Israel',
       'South Korea', 'Canada', 'France', 'Russia', 'China', 'Taiwan',
       'Sweden', 'Singapore', 'Denmark', 'Germany', 'Netherlands',
       'Italy', 'Belgium', 'Australia', 'Finland', 'Norway',
       'South Africa', 'Spain', 'Brazil', 'Hong Kong', 'Ireland',
       'Austria', 'New Zealand', 'Portugal', 'Thailand', 'Czech Republic',
       'Malaysia', 'India', 'Greece', 'Mexico', 'Hungary', 'Argentina',
       'Turkey', 'Poland', 'Saudi Arabia', 'Chile', 'Iceland', 'Slovenia',
       'Estonia', 'Lebanon', 'Croatia', 'Colombia', 'Slovak Republic',
       'Iran', 'Egypt', 'Serbia', 'Bulgaria', 'Lithuania', 'Uganda',
       'United Arab Emirates', 'Uruguay', 'Cyprus', 'Romania',
       'Puerto Rico'], dtype=object)
```
In [44]:
```
np.unique(country_le)
```
Out[44]:
```
array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16,
       17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33,
       34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50,
       51, 52, 53, 54, 55, 56, 57, 58])
```
In [45]:
```
le_country.inverse_transform([n for n in range(59)])
```
Out[45]:
```
array(['Argentina', 'Australia', 'Austria', 'Belgium', 'Brazil',
       'Bulgaria', 'Canada', 'Chile', 'China', 'Colombia', 'Croatia',
       'Cyprus', 'Czech Republic', 'Denmark', 'Egypt', 'Estonia',
       'Finland', 'France', 'Germany', 'Greece', 'Hong Kong', 'Hungary',
       'Iceland', 'India', 'Iran', 'Ireland', 'Israel', 'Italy', 'Japan',
       'Lebanon', 'Lithuania', 'Malaysia', 'Mexico', 'Netherlands',
       'New Zealand', 'Norway', 'Poland', 'Portugal', 'Puerto Rico',
       'Romania', 'Russia', 'Saudi Arabia', 'Serbia', 'Singapore',
       'Slovak Republic', 'Slovenia', 'South Africa', 'South Korea',
       'Spain', 'Sweden', 'Switzerland', 'Taiwan', 'Thailand', 'Turkey',
       'USA', 'Uganda', 'United Arab Emirates', 'United Kingdom',
       'Uruguay'], dtype=object)
```
In [46]:
```
data_no_null.head()
```
Out[46]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	pul
200	1	Harvard University	USA	1	1	1	1	
201	2	Stanford University	USA	2	11	2	4	
202	3	Massachusetts Institute of Technology	USA	3	3	11	2	
203	4	University of Cambridge	United Kingdom	1	2	10	5	
204	5	University of Oxford	United Kingdom	2	7	12	10	

In [47]:

```
data_digit = data_no_null.copy()
#data_digit.pop('institution')
#data_digit.pop('country')
data_digit["institution"] = institution_le
data_digit['country'] = country_le
data_digit
```

Out[47]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	public
200	1	184	54	1	1	1	1	
201	2	511	54	2	11	2	4	
202	3	312	54	3	3	11	2	
203	4	637	57	1	2	10	5	
204	5	819	57	2	7	12	10	
...	...	...	...	...	...	...	...	...
2195	996	954	37	7	367	567	218	
2196	997	11	14	4	236	566	218	
2197	998	132	4	18	367	549	218	
2198	999	576	48	40	367	567	218	
2199	1000	74	8	83	367	567	218	

2000 rows × 14 columns

Проверяем типы данных

In [48]:
```
data_digit.dtypes
```

Out[48]:
```
world_rank            int64
institution           int64
country               int64
national_rank         int64
quality_of_education  int64
alumni_employment     int64
quality_of_faculty    int64
publications          int64
influence             int64
citations             int64
broad_impact        float64
patents               int64
score               float64
year                  int64
dtype: object
```

Вспомагательные функции

In [49]:
```
def diagnostic_plots(df, variable):
    plt.figure(figsize=(15,6))
    # гистограмма
    plt.subplot(1, 2, 1)
    df[variable].hist(bins=30)
    ## Q-Q plot
    plt.subplot(1, 2, 2)
    stats.probplot(df[variable], dist="norm", plot=plt)
    plt.show()
```

Графики по набору данных

Построим основные гистограммы по этому набору данных

In [50]:
```
data_no_null.hist(figsize=(20,20))
plt.show()
```

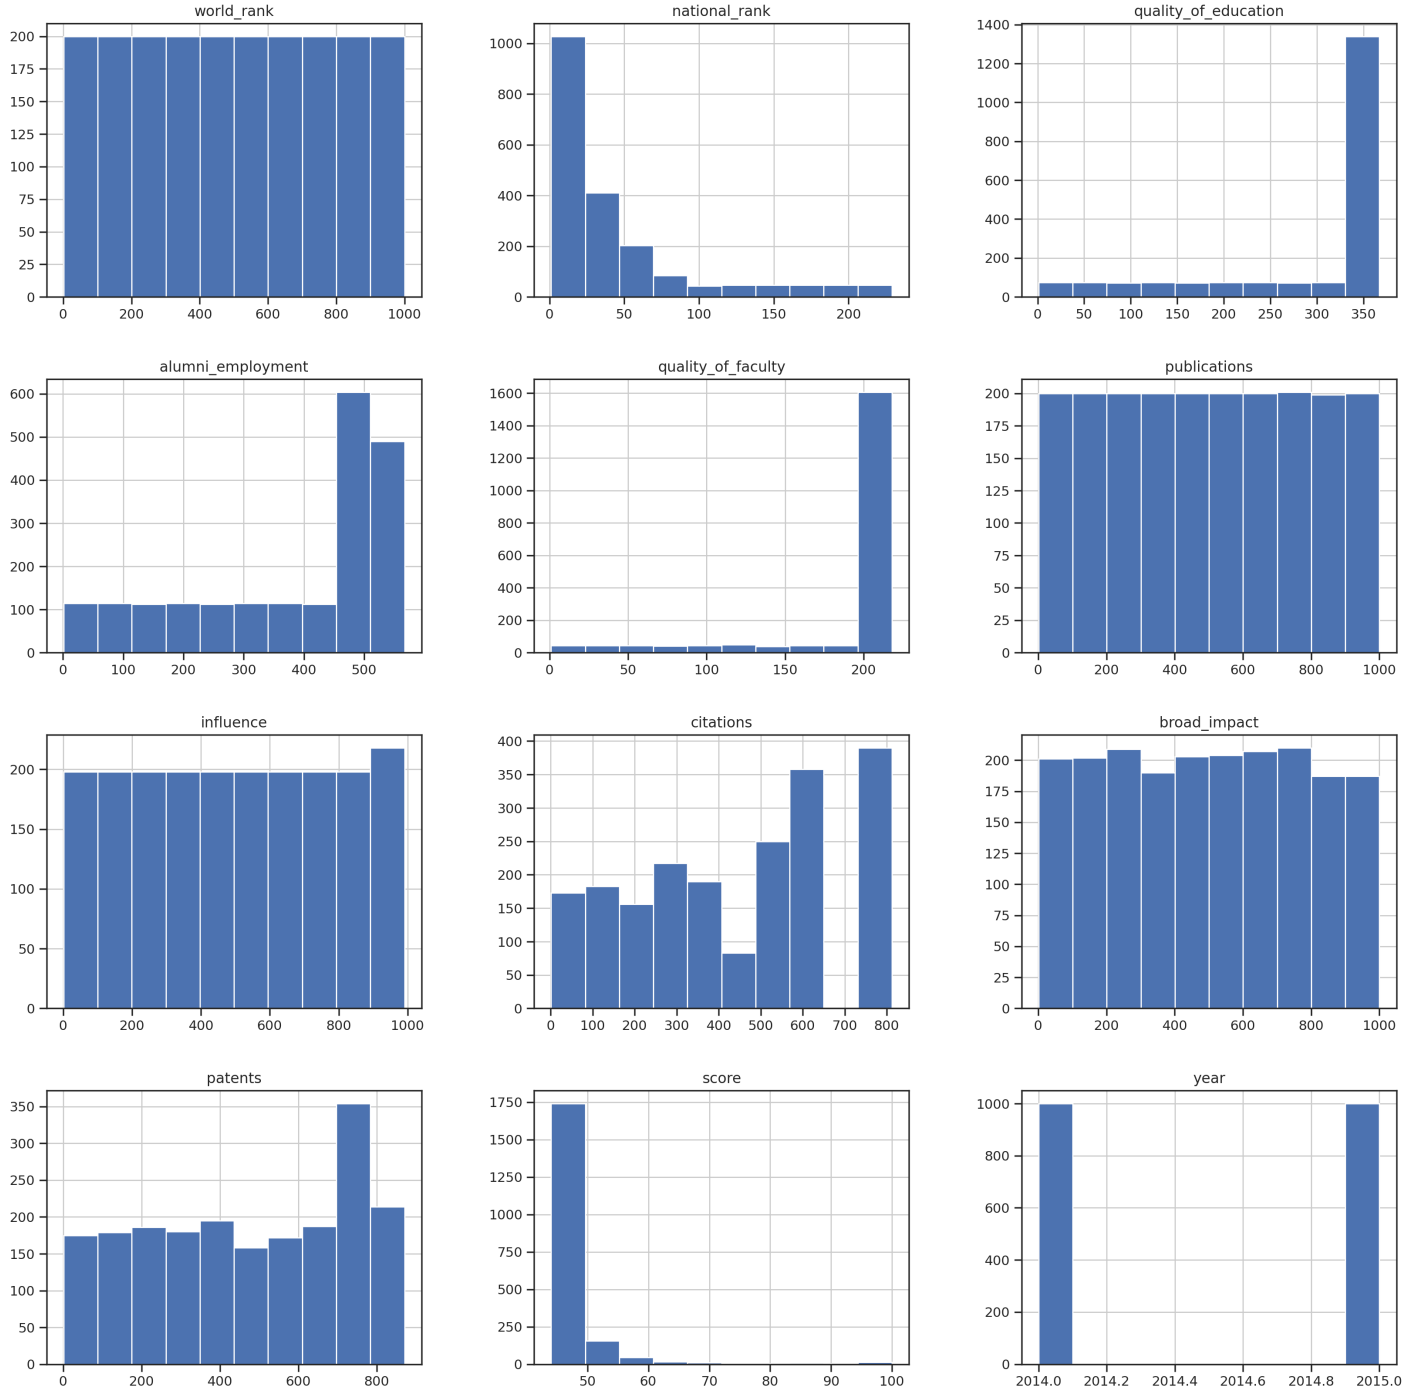

Нормализация данных (задача №15)

Нормализация методом возведения в степень выполнена на колонке `citations`

In [51]:
```
data_normal = data_no_null.copy()
data_normal['patents'] = data_no_null['patents']**(1/2)
diagnostic_plots(data_normal, 'patents')
```

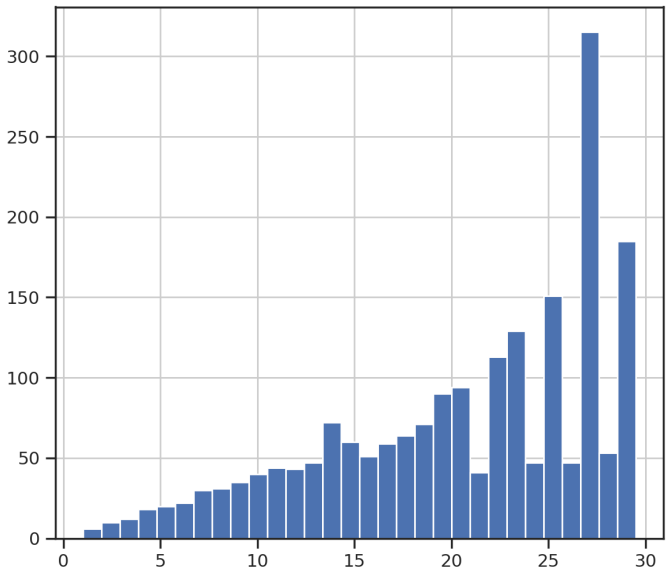

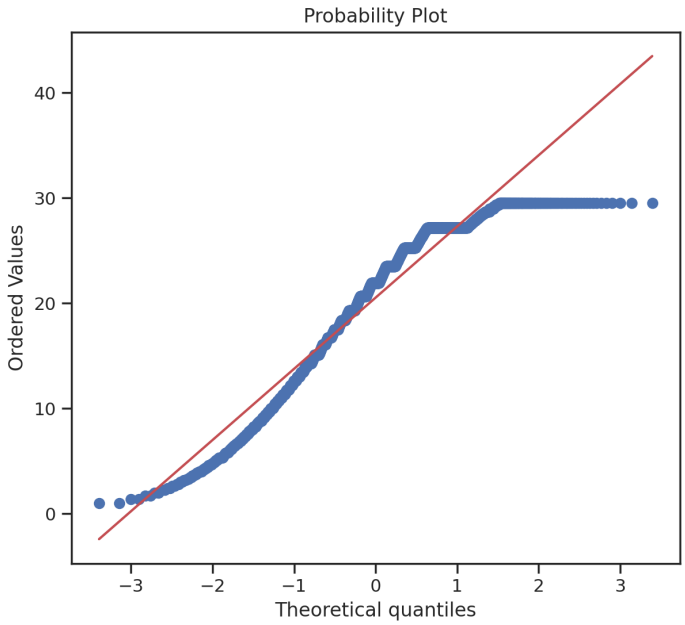

Отбор признаков (задача №35)

Для отбора будем использовать методы вложений с использованием решающего дерева. В иРК будет использован `DecisionTreeRegressor`

Отделим целевой признак `world_rank`

In [52]:
```
data_x = data_digit.copy()
data_x = data_x.drop(columns='world_rank')
data_x
```

Out[52]:

	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	publications	influe
200	184	54	1	1	1	1	1	
201	511	54	2	11	2	4	5	
202	312	54	3	3	11	2	15	
203	637	57	1	2	10	5	10	
204	819	57	2	7	12	10	11	
...	...	...	...	...	...	...	...	
2195	954	37	7	367	567	218	926	
2196	11	14	4	236	566	218	997	
2197	132	4	18	367	549	218	830	
2198	576	48	40	367	567	218	886	
2199	74	8	83	367	567	218	861	

2000 rows × 13 columns

In [55]:
```
data_y = data_digit['world_rank']
data_y
```

Out[55]:
```
200       1
201       2
202       3
203       4
204       5
        ...
2195    996
2196    997
2197    998
2198    999
2199   1000
Name: world_rank, Length: 2000, dtype: int64
```
In [56]:
```
dtc1 = DecisionTreeRegressor()
dtc1.fit(data_x, data_y)

# Важность признаков
dtc1.feature_importances_, sum(dtc1.feature_importances_)
```
Out[56]:
```
(array([5.27838667e-05, 9.02680188e-06, 1.16551290e-04, 2.72980370e-04,
        4.48968033e-03, 4.87300105e-04, 4.48830192e-04, 6.51929437e-05,
        4.53535493e-05, 1.07482543e-01, 1.99057595e-03, 8.79654143e-01,
        4.88503893e-03]),
 1.0)
```
In [57]:
```
from operator import itemgetter

def draw_feature_importances(tree_model, X_dataset, title, figsize=(7,4)):
    """
    Вывод важности признаков в виде графика
    """
    # Сортировка значений важности признаков по убыванию
    list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances_))
    sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
    # Названия признаков
    labels = [x for x,_ in sorted_list]
    # Важности признаков
    data = [x for _,x in sorted_list]
    # Вывод графика
    fig, ax = plt.subplots(figsize=figsize)
    ax.set_title(title)
    ind = np.arange(len(labels))
    plt.bar(ind, data)
    plt.xticks(ind, labels, rotation='vertical')
    # Вывод значений
    for a,b in zip(ind, data):
        plt.text(a-0.1, b+0.005, str(round(b,3)))
    plt.show()
    return labels, data
```
Выведем гистограмму с важностью признаков

In [58]:
```
_,_=draw_feature_importances(dtc1, data_x, 'Решающее дерево')
```

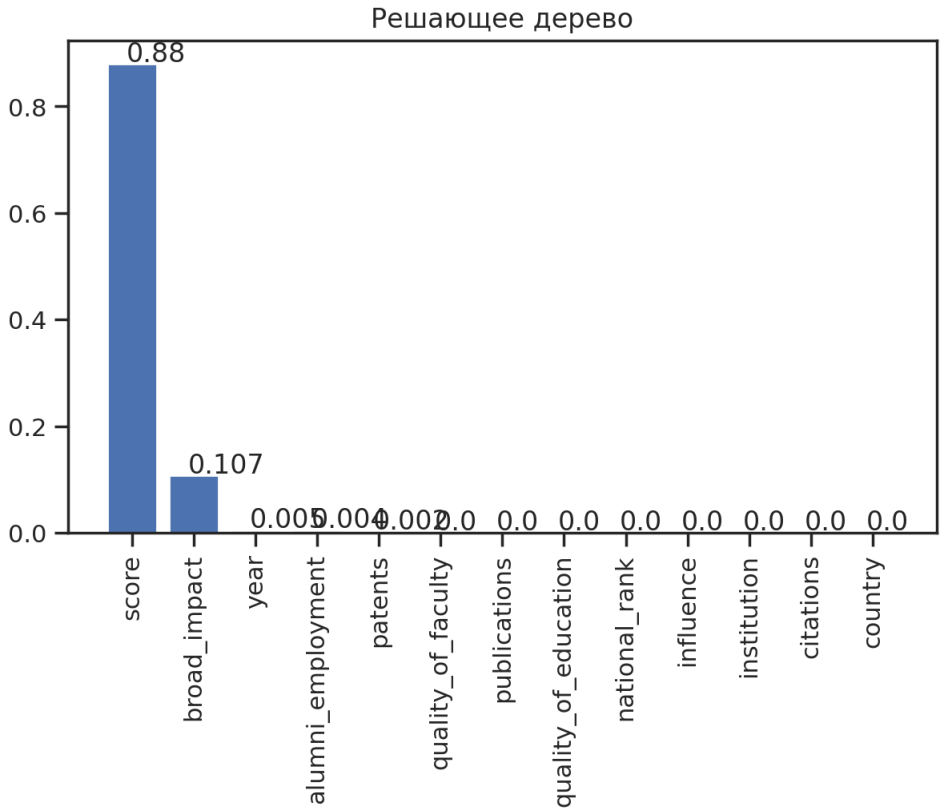

Таким образом, отбор ведётся по признакам `scoe` и `broad_impact` . Также немного учавствует признак `year` , который по смысловому контексту можно отбросить. Вес остальных признаков = 0.

Гистограмма для колонки (задание для группы ИУ5-22М)

In [60]:

```
plt.hist(data['broad_impact'], 50)
plt.xlabel('broad_impact')
plt.show()
```

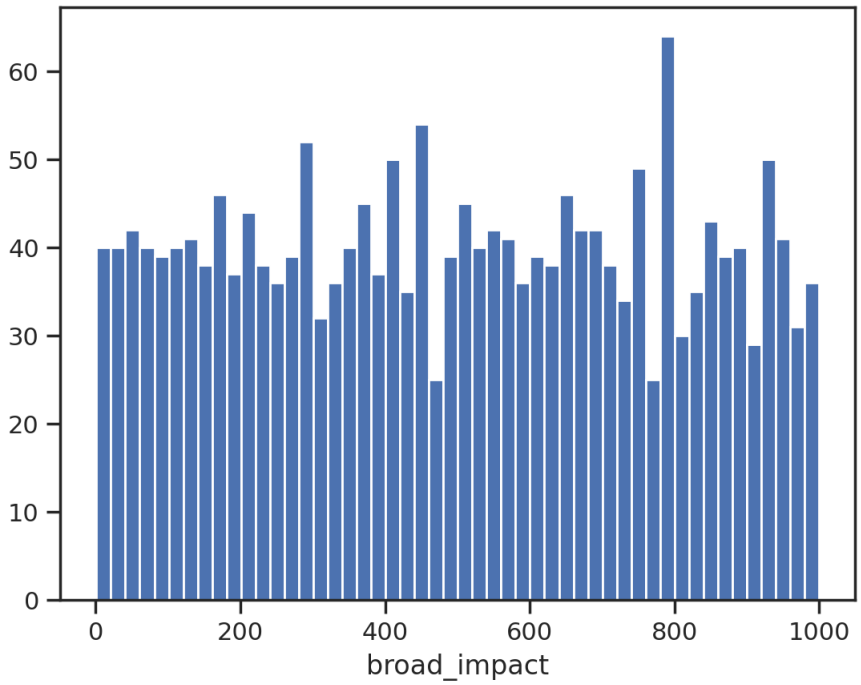

In [ ]: